



PDF 文件處理與向量化系統架構

本系統展示了從使用者上傳 PDF 到資料儲存的完整流程，包含文件解析、分塊處理、向量嵌入及多層儲存架構。

系統架構總覽



整個系統採用三層架構設計，確保使用者上傳的 PDF 文件能夠順利通過 API 層傳遞到後端服務進行處理。

文件處理流程

PDF Extract

使用 **PyPDF2** 進行 PDF 文件內容提取

- 解析 PDF 文件結構
- 提取文字內容
- 保留文件格式資訊

Chunking

將提取的內容分塊處理，每塊 **1000 字元**

- 智能分段
- 保持語意完整性
- 優化檢索效率





向量嵌入技術

Embedding

採用 **BGE-M3** 模型進行向量嵌入

- 高維度向量表示
- 語意相似度計算
- 支援多語言處理

BGE-M3 是一個先進的嵌入模型，能夠將文字內容轉換為高維度向量，為後續的相似度搜尋和語意檢索提供基礎。

雙層儲存架構

FAISS Store

向量儲存

專門儲存文件的向量表示，支援高效的相似度搜尋和快速檢索。FAISS 提供了優化的索引結構，能夠在大規模向量資料中快速找到最相似的結果。

SQLite

元資料儲存

儲存文件的元資料資訊，包括文件名稱、上傳時間、分塊資訊等結構化資料。SQLite 提供了輕量級但功能完整的關聯式資料庫支援。

完整資料流程

01	02	03
使用者上傳 PDF	API 層接收	服務處理
User uploads PDF	API Layer - skills.py	Services - Ingestion
04	05	06
PDF 提取	內容分塊	向量嵌入
PDF Extract (PyPDF2)	Chunking (1000 chars)	Embedding (BGE-M3)
07		
雙層儲存		
FAISS Store (Vectors) + SQLite (Metadata)		

從使用者上傳到最終儲存，系統確保每個步驟都經過精心設計，實現高效、可靠的文件處理與檢索能力。