

這是一份為您重新優化、整合多文件支援說明，並結合系統架構與未來展望的完整 README.md。這份文件特別強化了對多種格式（PDF, DOCX, PPTX, MD, TXT）支援的描述，並保持專業且易讀的結構。

KnowledgeLM：全方位本地化知識檢索增強生成系統

版本： 1.0 (2025-12-04) **定位：** 您的企業級數位圖書館員 —— 支援多格式文檔分析，打造私有化精準知識庫。

KnowledgeLM 是一款基於 **FastAPI** 與 **Python 3.11** 構建的高性能 RAG (Retrieval-Augmented Generation) 系統。它能深度整合您的本地文檔，透過先進的語義搜索與大語言模型（LLM），提供精準的問答與知識合成服務。

系統概述

KnowledgeLM 採用「**雙重 RAG 架構**」(Dual RAG Architecture)，針對不同規模與需求的知識管理提供最佳路徑：

- 1. 技能導向 RAG (Skill-Based RAG)：**
 - 將多份關聯文件（不限格式）歸納為單一「技能 (Skill)」知識領域。
 - 使用 **FAISS** 向量資料庫實現物理隔離，確保特定領域問答的精確度與安全性。
 - 4. 文件導向 RAG (File-Based RAG)：**
 - 針對獨立檔案進行快速索引，適合海量分散文檔的全局檢索。
 - 整合 **Milvus** 高性能向量引擎，支援複雜的 5 階段 OPMP 處理管道。
-

核心功能與多文件支援

全方位的多格式支援

系統內建強大的解析引擎，支援以下文件類型的自動化攝取與分塊處理：

- **PDF (.pdf)：** 支援複雜版面解析與文本提取。
- **Word (.docx)：** 完整攝取辦公文檔內容。
- **PowerPoint (.pptx)：** 解析簡報投影片中的關鍵資訊。
- **Markdown (.md)：** 原生支援結構化技術文檔。
- **純文本 (.txt)：** 支援各類標準文本資料。

智能處理技術

- **本地化隱私保護**：支援透過 **Ollama** 運行本地 LLM，確保數據處理完全不出機房。
- **高維度語義向量**：採用 BAAI/bge-m3 模型，提供 1024 維度的多語言嵌入，極大提升中英文檢索相關性。
- **動態模型管理**：內建 LLManager，支援在運行時切換不同的模型（如從 phi4 切換至 Llama 3），靈活應對不同任務。
- **查詢優化策略**：整合「多輪查詢擴展」技術，自動將模糊的問題拆解為具體的子查詢，顯著降低模型幻覺。

技術棧 (Technology Stack)

組件	技術選擇	用途
後端框架	Python 3.11, FastAPI	高並發非同步 API 處理
向量庫 (Skill)	FAISS	本地、輕量、隔離的向量索引
向量庫 (File)	Milvus	大規模全局向量搜索服務
元數據庫	SQLite / MongoDB	儲存技能定義、檔案關聯及對話歷史
嵌入模型	BAAI/bge-m3	多語言語義理解與向量化
推理引擎	Ollama / OpenAI	答案生成與文本理解

專案架構 (Project Structure)

DOCAI/ (Project Root)	
├─ app/	# 核心程式碼庫
│ └─ api/v1/	# 接口層：定義上傳、對話、模型切換路由
│ └─ core/	# 核心配置：系統參數與環境變數管理
│ └─ Providers/	# 基礎設施：LLM、Embedding、DB 驅動
│ └─ Services/	# 檔案 RAG 邏輯：處理單一文件的檢索增強
│ └─ SkillServices/	# 技能 RAG 邏輯：處理跨文件領域知識
├─ data/	# 數據存儲
│ └─ faiss_indices/	# 物理 FAISS 索引檔
│ └─ files/	# 存儲上傳的原始文檔（PDF，DOCX等）
│ └─ skill_metadata.db	# 技能架構元數據
└─ template/	# 前端介面：Jinja2 模板與 UI 組件

系統優點與未來展望

系統亮點

- **格式無縫對接**：統一的 Ingestion Pipeline，讓不同格式的文件能協同工作。

- **極致彈性**：可根據硬體環境選擇 FAISS (輕量) 或 Milvus (強大) 向量後端。
- **開發友好**：清晰的層級設計，方便擴展新的 Embedding 模型或檢索演算法。

未來發展 (Roadmap)

- **自動化摘要**：為每個新上傳的文件或技能自動生成概覽說明。
- **GraphRAG 整合**：引入知識圖譜技術，強化對文檔間複雜關係的推理能力。
- **OCR 強化**：針對掃描版 PDF 與圖片提供更精準的文字識別支援。

希望這份 README.md 能完美呈現您系統的強大功能！如果您需要針對特定的安裝步驟或 API 文件進行補充，隨時告訴我。