

人文社會AI導論
第七集：自然語言處理簡介

自然語言處理（ Natural Language Processing ）的困難之處

自然語言處理是AI發展最重要也是最困難的挑戰，因為語言或文字是最接近人類思想的表現方式。包括對人類語言的「理解」、「翻譯」、「對話」和「生成」等等。AI的圖靈測試也是以文字溝通作為人工智慧的成功與否的定義。由於語音辨識仍多半需要先轉換成文字來理解，本集僅先以文字處理為主要的考慮。

為何自然語言處理特別困難？主要是來自於語言定義與概念的不確定性：

1. 語言/文字是一種「聲音/形象符號」，指涉某種概念（或實體）。但因為語言是約定成俗的結果，與當時當地的文化習慣相關，非恆常不變（如一詞多義、人名、專業用語、方言習慣），因此難有明確清晰的標註資料來協助訓練。
2. 語言/文字又「不只是符號」，即使指涉同一事物也因為使用的上下文不同，而帶有某種閱讀心理所累積的預設，具有曖昧性、歧異性與隱藏性（如暗示、諷刺、笑話等）。如果嚴格限定使用方式，反而不像真正的人類說話。

中文斷詞的問題

中文並非拼音文字，處理前需要先斷詞。一般字/辭典的語料遠遠不足，不但新詞需要補充，也要處理人名、虛詞、歧義、專有名詞、縮寫、多義組合等。如果不考慮上下文之間藉由統計學處理所新生的詞彙，中文自然語言處理將成為不可能。

一般斷詞的步驟：

1. 初步斷詞
2. 未知詞偵測
3. 人名擷取
4. 譯名擷取
5. 複合詞擷取
6. 用統計方法找出特殊詞彙
7. 重新斷詞

以「大學生了沒」為例，計算此字串出現的機率：

$$P(\text{大學生了沒}) \sim P(\text{沒/了}) \times P(\text{了/生}) \times P(\text{生/學}) \\ \times P(\text{學/大}) \times P(\text{大})$$

$P(\text{生/學})$ = 在出現“學”的前題下，後面出現“生”這個字的機率

通常 $P(\text{學/大})$ 與 $P(\text{生/學}) \gg P(\text{了/生}) \gg P(\text{沒/了})$

➔ 選擇較長而有意義的字串「大學生」作為新的詞彙

斷詞		次數
1	我	321
2	你	212
3	的	201
4	她	152
5	了	122
6	放假	43
7	常常	28
8	學校	23
9	IG	18
10	大學生	12

指代消解(Coreference Resolution)的問題

一篇文章中往往含有許多代名詞，代表前後所出現的人名或名詞片語。一般程度的文章與讀者都可以準確地從前後文了解這些代名詞的具體指稱，但是對AI的自然語言處理而言，要完美解決這個指代消解問題卻相當困難。這可能會大大影響對於文章意義的正確解讀或文字表達。

舉例：[張小明]對人很熱情，大家都叫[他][阿明]。[阿明]是台北郊區某間私立高中的學生，在學校很得[同學]的喜愛。有一次[他]的[同學][小王]來找[他]：「[阿明]，[你]一定要趕快找到上次被[你]弄丟的耳機，因為[那]是[我][爸爸]送[我][弟弟]的生日禮物，找不到[我]會被[他]修理得很慘。」



要解決指代消解的問題無法只靠規則，也需要訓練機器學習的模型，來預測這些代名詞是用前後文哪一個實體對象。這顯示自然語言處理為何比想像中困難，並非只是出現次數比較多或距離比較近的就是比較相關。


文章關鍵字

事實上，文本中「出現最多次數」的詞語也不見得是真正的關鍵字，因為一些常用字詞（如我、的、個等代名詞或虛詞）常常並非重點。**tf-idf (term frequency–inverse document frequency)** 是一種將此文本中所常用，但並非其他文章中所常用的字，藉由統計分析的方式計算出來，提供出較為適合的關鍵字蒐集。

第x的詞彙在
第y個文件的重要性

$$w_{x,y} = \text{tf}_{x,y} \times \log \left(\frac{N}{\text{df}_x} \right)$$


$\text{tf}_{x,y}$ = frequency of x in y
 df_x = number of documents containing x
 N = total number of documents



	次數多	次數少
重要	可發現	難發現
不重要	需刪除	可忽略



詞向量作為自然語言處理的基礎

關鍵字詞僅有詞頻的資訊，仍沒有前後字詞的文意關係。「詞向量」(Word2Vec)即是藉由類神經網路計算大量文本中各字詞與前後字詞的關係，將之編碼成高維度的向量，好讓電腦可以處理各類自然語言的任務。網路上也有一些已經利用巨量資料預先訓練好的結果(如Bert)可以下載使用。




文章主題模型 (LDA)

在文章分類的時候，多半是找出相關的「主題」（例如政治性或體育性）。但這些主題往往不是文章用字，電腦該如何找出來？LDA (Latent Dirichlet Allocation) 是用無監督式學習來用「詞頻出現的分布方式」定義主題。利用不同文本在這些主題的分布比例不同，可作文章分類。但此計算出來的主題不見得能直觀的了解。



遞迴神經網路 (Recurrant Neural Network)

語言文字與圖像資料最大的不同，在於前者是有時間順序的資料，不可逆向。遞迴神經網路在每個輸入的字（詞向量）來運算時同時記憶並調整下次的參數，使字詞順序也會被學習起來，產生帶有順序的編碼。但RNN本身效率並不好，已有許多改進的版本（如GRU, LSTM, Seq2Seq, Transformer, etc.）





以文字生成的基本結構模型為例

翻譯上的應用

傳統上的電腦翻譯是仿照人類的思考邏輯，先決定字詞的意義與性質後，再藉由句法分析了解整個句子的意義，最後再產生另一種語言的對應表達。這樣的方式就需要大量倚賴語言學的知識，但實際效果卻遠不如人類翻譯。

2016年起，**Google**開始使用詞向量與類神經網路結合來進行翻譯，直接從已知文件的人類翻譯來學習，由前後文的關聯性來決定其對應翻譯的文字，在日常文件上已經大幅提升效果（專業寫作還有待提升）。甚至兩種沒有翻譯資料的語言之間亦能透過雙方都有翻譯的C語言來互譯。




對話機器人 (Chatbot)

對話機器人是AI發展的指標性應用之一，甚至一開始就是圖靈測試的基本模型。其困難處在於「動態性」的自然語言處理：需要理解對方所講的內容而生成對應的語言，讓對方覺得有達到溝通的目的。往往對話時間一長，就會發現錯誤百出。

1. 規則型：

Eliza是以人本心理學原理所設計的對話機器人，讓對方自問自答，釐清思緒。

Eliza有兩百多個模板，若偵測到對方話語中的關鍵字，就有對應的模板來回覆。若沒有，就只是把主詞從「我」改為「你」來回覆。



YOU: I think Sazae's family is good.
ELIZA: What caused you to feel that way?
YOU: Because the family members believe in themselves.
ELIZA: What other reasons might there be?
YOU: Well, I don't know.
ELIZA: I'd like to know more about your opinion.
YOU: I don't like my family so much.
ELIZA: That is quite interesting.
YOU: Yeah.
ELIZA: I'd like to know more about your opinion.
YOU: My family members aren't friendly, so I can't talk with them.
ELIZA: I see.
YOU: Do you have family?
ELIZA: Why do you think that?

Eliza (1960s)

對話機器人 (Chatbot)

2. 功能型：目前大部分的聊天機器人是用在電話客服，針對某些領域（如銀行、保險、醫療等）的使用者而設計的對話，**連結於資料庫來回應需求，並無語意理解的功能。**

3. 聊天型：通用型(對話沒有特定目的)的聊天機器人，是透過蒐集大量的對話資料來訓練AI的回應，並且從回應結果中再進行訓練強化。此模式可能產生流暢對話的原因除了在於人類大部分的對話還是有固定模式以外，對話者對機器通常更放心關注於自身的狀態而非其說話的動機。

但此種聊天機器人目前大部分只能作到發散型的回應，無法環繞固定的主題作有深度或目標性的對話，因此反而適合現代通訊軟體與社群媒體上的淺層溝通。

擷取自微軟小冰之父：上億用戶練出小冰情商
<https://images.app.goo.gl/LqNif8quP1Y87m7NA>



對話機器人 (Chatbot)

4. 智慧助理型：為了兼具不同目的通用型代理功能，除了能夠進行有意義內涵的聊天，也要能夠分析對方語言來擷取準確的訊息，才能有適當的回應與行動（如Apple Siri，Google Assistant，IBM Watson，Amazon Alexa etc）。需要同時進行語意分析、知識庫搜尋以及行動解決方案等。



Credit to NY Times:

<https://www.nytimes.com/2011/02/17/science/17jeopardy-watson.html>

Credit to Google I/O 2018 Duplex:

https://www.youtube.com/watch?v=yv_8dx7g-WA

「自然語言處理簡介」小結

1. 自然語言處理 (NLP) 是目前人工智慧應用中最困難的挑戰之一，因為牽涉到語言的脈絡性、文化性、時代性與思想性，很難有明確的定義讓電腦可以遵循或學習。斷詞與指代消解的問題就顯示出此類問題的複雜性。
2. 傳統關鍵字分析的方式無法掌握語意真實的內涵，在應用上很難滿足AI的需求。加入無監督式的主題模型 (LDA) 或詞向量 (Word2vec) 可以計算其間的關聯性，掌握文中一部分的語意或使用方式。
3. 若要考慮字詞前後的順序則需要使用如遞迴神經網路 (RNN) 與其相關的衍伸應用，才能產生比較有意義的文字生成或語言翻譯。這部分在特定類型的文字上已能有相當的效果。
4. 類似人類溝通與理解能力的智慧對話機器人需要整合許多更為複雜的技術，是未來AI應用發展的重要指標。